

Pronóstico de Demanda Energética en Colombia

Daniel de Jesús Martínez Vega

I. INTRODUCCIÓN

La demanda de energía es un fenómeno complejo que está influenciado por una gran variedad de factores, como el clima, las condiciones económicas, los días festivos y los eventos especiales. Esta variabilidad hace que sea difícil para las empresas y operadores del sector energético predecir con precisión la cantidad de energía que se necesitará en un momento dado. En Colombia, el CND (Centro Nacional de Despacho) publica los martes su propuesta de pronóstico correspondiente a la semana comprendida entre el lunes siguiente y el domingo posterior a ese lunes, y los viernes a más tardar a las 13:00 horas su pronóstico definitivo. En este documento se presenta la experimentación realizada con distintos modelos de machine learning (Regresión lineal, Máquinas de soporte vectorial, Árboles de decisión, Gradient Boosting y Perceptrones multicapa) para el desarrollo de un modelo para generar un pronóstico los días viernes a las 12:00 horas de la demanda energética en Colombia de la semana siguiente, el cual puede ser de ayuda para planificar de forma informada mantenimientos, precios, generación y distribución de energía en el país. El desempeño de los distintos modelos fue comparado usando las métricas MAPE(Error Porcentual Absoluto Medio) y MAE (Error Absoluto Medio).

II. DATOS UTILIZADOS

Para el desarrollo de este proyecto se usó información proveniente del API de XM, el operador del Sistema Interconectado y el administrador del Mercado de Energía Mayorista de Colombia. Esta API dispone de información actualizada sobre el estado de los embalses usados para la generación de energía, demanda comercial energética total del país y dividida por agentes y operadores, oferta y generación de energía, precios, exportaciones e importaciones.

Para poder interactuar con esta API, la empresa pone a disposición la librería de python pydataxm, la cual permite extraer datos de forma estructurada sobre cada una de estas fuentes de información con las que cuenta.

En este proyecto se utilizó para el entrenamiento de los modelos el histórico de la demanda real total en todo el país desde el primero de mayo de 2020 al 20 de mayo de 2024. Esta fuente proporciona la demanda en kilovatios hora

(Kwh) de todo el país en cada una de las horas del día en un formato tabular de 27 columnas donde las primeras dos proporcionan información sobre la fuente de los datos, las siguientes 24 contienen el valor de demanda cada hora y la última columna contiene la fecha en la que se produjeron estos datos, por supuesto, esta información tiene que ser procesada para ser estructurada en un formato con el cual se pueda entrenar correctamente los modelos.

En Fig. 1. Se muestra un ejemplo de la estructura de los datos entregados por el API al hacer una petición usando la librería pydataxm.

```
[ ] # Descarga de datos
# =====
objetoAPI = pydataxm.readAPI()
df = objetoAPI.request_data("demanda", "Sistema", dt.date(2020, 1, 1), dt.date(2024, 2, 6));

[ ] df.head()
```

	Id	Values_code	Values_Hour01	Values_Hour02	Values_Hour03	Values_Hour04	Values_Hour05	Values_Hour06	Values_Hour07	Values_Hour08
0	Sistema	Sistema	6510932.21	6355934.69	6198901.87	6035914.25	5926115.96	5808393.07	5410352.96	5453957.80
1	Sistema	Sistema	6217017.34	5983569.69	5855588.80	5773524.46	5850155.12	6041095.49	6163861.00	6652958.08
2	Sistema	Sistema	6947913.59	6657191.41	6486555.64	6306541.70	6405625.97	6617854.66	6699945.65	7136216.67
3	Sistema	Sistema	7070821.48	6785318.72	6610262.84	6481000.84	6490961.64	6579718.56	6572961.51	6971699.82
4	Sistema	Sistema	7011678.32	6719639.11	6531431.83	6381768.46	6303910.16	6271333.56	6078660.63	6287003.96

5 rows * 27 columns

Fig. 1. Estructura original de los datos que serán utilizados en el proyecto.

A. Análisis exploratorio de datos

Antes del desarrollo de los modelos es necesario hacer un análisis exploratorio de los datos para identificar patrones, que ayuden a identificar posibles predictores, transformaciones y modelos que ayuden a identificar el comportamiento en la serie de tiempo.

1. Serie de tiempo:

En Fig. 2. Se presentan dos gráficas de líneas con la serie temporal completa y una porción de esta (Mayo de 2023). Primero que todo, la serie temporal toma valores entre 500.000 y 1.200.000 kilowatts. Adicionalmente, los patrones más destacables del gráfico superior son la tendencia ascendente del consumo a medida que pasan los años y los picos de bajo consumo que corresponden a semana santa y las primeras y últimas semanas del año.




Fig. 2. Visualización de la serie completa y una sección de esta.

Por otra parte, en la sección detallada de la gráfica inferior, se puede ver que hay una clara estacionalidad semanal, con consumos más elevados durante la semana laboral (lunes a viernes), se reduce un poco los sábados y donde se destaca que es mucho menor es los domingos. Se observa también que existe una clara correlación entre el consumo de un día con el de un día antes y una semana antes. Por último, esta sección tiene dos lunes festivos (1 y 22 de mayo) y se ve que su consumo es menor al de los otros lunes (8 y 29 de mayo).

2. Gráficos de estacionalidad:

Los gráficos de estacionalidad permiten identificar de forma más detallada posibles patrones cíclicos en el comportamiento de la serie de tiempo.

- Estacionalidad anual: En Fig. 3. Se presenta la gráfica de estacionalidad anual de la serie de tiempo. Se observa que hay una estacionalidad anual, donde Febrero, Marzo y Septiembre son los meses con mayor valor de demanda (mediana).




Fig. 3. Gráfico de estacionalidad Anual.

- Estacionalidad semanal: En Fig. 4. Se presenta la gráfica de estacionalidad semanal de la serie de tiempo. Se aprecia una estacionalidad semanal, con valores de demanda inferiores durante el fin de semana y los lunes (habría que revisar la influencia de los días festivos)




Fig. 4. Gráfico de estacionalidad Semanal.

- Estacionalidad diaria: En Fig. 5. Se presenta la gráfica de estacionalidad diaria de la serie de tiempo. También existe una estacionalidad diaria, la demanda tiende a bajar de 10 pm a 5 am y tiende a subir de 6 am a 9 pm con una pequeña baja a las 7 pm.




Fig. 5. Gráfico de estacionalidad Diaria.

3. Influencia de los días festivos:

Otro posible factor que puede afectar el comportamiento de la demanda son los días festivos, como se pudo observar en el gráfico de estacionalidad semanal, en los días no laborales (Sábado y Domingo) la demanda energética tiende a ser menor, por lo que el consumo en los días festivos debería tener un comportamiento similar. Para confirmar esta hipótesis, Fig. 6. Muestra una comparativa de la distribución entre los días festivos y días no festivos (Incluyendo Sábados y Domingos). Se puede observar que en los días no festivos la demanda llega a valores más altos que en los festivos.




Fig. 6. Distribución de demanda en días festivos (Naranja) y No Festivos (Azul).

Adicionalmente, En Fig. 7. se proyecta nuevamente el gráfico de estacionalidad nuevamente pero sin incluir festivos. Se puede ver que con este cambio la distribución de los lunes es pareja con la del resto de días laborales.




Fig. 7. Gráfico de estacionalidad Semanal (Sin Festivos).

Por último, En Fig. 8. se presentan las curvas de demanda promedio en cada hora diferenciado por el día de la semana y separando los días festivos. El consumo de demanda de energía en el país se encuentra marcado por una tendencia dependiendo del tipo de día, por ejemplo, entre el lunes y viernes se mantiene un consumo promedio, el cual puede ser clasificado como un día ordinario. El sábado mantiene un consumo particular, el cual puede seguir siendo identificado de esta forma, mientras que los días domingos y festivos es posible agruparlos dado su consumo de energía eléctrica similar.




Fig. 8. Curvas de demanda promedio.

4. Gráficos de autocorrelación:

Los gráficos de autocorrelación permiten identificar la correlación entre valores de una serie de tiempo y valores atrasados de esta. Fig. 9. Muestra un gráfico de autocorrelación de la serie de tiempo. El aspecto más destacable es el comportamiento sinusoidal del gráfico en el que se identifica una fuerte correlación del consumo con horas anteriores y horas cercanas los días anteriores donde el pico más alto se presenta una semana antes (168 lags).




Fig. 9. Gráfico de autocorrelación.

Adicionalmente, el gráfico de autocorrelación parcial de Fig. 10. muestra una clara asociación entre la demanda de una hora y las horas anteriores, así como entre la demanda de una hora y la demanda de esa misma hora los días anteriores. Este tipo de correlación, es un indicativo de que valores anteriores de la serie de tiempo aportan información significativa a la hora de diseñar el modelo de pronóstico.




Fig. 10. Gráfico de autocorrelación parcial.

B. Procesamiento de los Datos:

Una vez identificados los patrones de la serie de tiempo (estacionalidad, efecto de los días festivos y autocorrelación con horas y días cercanos). En esta sección se explica el preprocesamiento realizado a la serie de tiempo para generar los predictores con los que serán entrenados los modelos.

1. Estructuración de los datos crudos:

Como ya se explicó al inicio de este capítulo, la librería utilizada proporciona los datos en un formato tabular de 27 columnas donde las primeras dos proporcionan información sobre la fuente de los datos, las siguientes 24 contienen el valor de demanda cada hora y la última columna contiene la fecha en la que se produjeron estos datos. Para que estos datos puedan ser procesados por los modelos que serán utilizados en este proyecto, se debe reestructurar estos datos en un formato cuyo índice contenga la fecha y hora en la que se tomó el dato y el valor de su única columna sea la demanda en esa determinada hora. En Fig. 11. se presenta una pequeña muestra de los datos reestructurados.

Demanda	
2024-05-10 01:00:00	8107265.19
2024-05-10 02:00:00	7852020.37
2024-05-10 03:00:00	7682999.06
2024-05-10 04:00:00	7596553.66
2024-05-10 05:00:00	7778720.95

Fig. 11. Datos reestructurados.

2. Lags (valores anteriores de la serie de tiempo):

En el análisis exploratorio de los datos se identificó una fuerte correlación del consumo con horas anteriores y horas cercanas los días anteriores donde el pico más alto se presenta una semana antes, teniendo en cuenta este detalle, entre los predictores que serán utilizados para generar los pronósticos de demanda se agregaran los 250 valores anteriores de la serie de tiempo, se eligió este número debido a la alta influencia del valor de una semana atrás (168 lags) en el valor actual de la serie de tiempo y a que el objetivo del modelo es predecir los viernes los valores hasta el domingo de la próxima semana, lo que equivale a 228 pasos hacia adelante. De esta forma se garantiza que se utilizará información no pronosticada por el modelo para generar predicciones.

3. Variables exógenas relativas a los días festivos:

Las variables exógenas son factores externos que influyen en el comportamiento del sistema pero no al revés. Estas variables se agregan como predictores adicionales al modelo con el fin de mejorar la precisión de los pronósticos generados debido a la información que aportan sobre el comportamiento de la serie de tiempo. Por ejemplo, en el análisis exploratorio de los datos se identificó que en los días festivos cambia significativamente la distribución de la demanda energética por lo cual, se agrega como variable exógena una variable binaria que indica si el día es un día festivo. Adicionalmente, ya que los modelos usan la demanda de días anteriores para generar predicciones, se agregarán otras cuatro variables binarias que indican si el día anterior es festivo, si el día siguiente es festivo, si el día de hace una semana es festivo y si el día de la próxima semana es festivo.

4. Variables exógenas relativas a la fecha:

Para incluir el efecto de la estacionalidad identificada en el análisis exploratorio como parte de los predictores, serán agregadas otras 8 variables exógenas con información relacionadas a el día de la semana, mes del año, hora del día y semana del año de la demanda que se busca pronosticar. Dado que todas estas variables tienen un comportamiento cíclico, para tener en cuenta también este efecto se utilizarán las funciones seno y coseno para representar estos patrones cíclicos en el comportamiento de los datos.

En Fig. 12. y Fig. 13. se muestra como el día de la semana y el mes del año son codificados variables con codificados con las funciones seno y coseno para mantener el comportamiento cíclico de las variables




Fig. 12. Codificación trigonométrica del día de la semana.




Fig. 13. Codificación trigonométrica del mes del año.

5. Normalización de los valores de demanda:

Por último, para reducir el tiempo y costo computacional del entrenamiento de los modelos, además de mantener en un rango de valores parecido las variables utilizadas para generar los pronósticos, se hará una normalización estándar a los valores de demanda.

III. METODOLOGÍA

Para el desarrollo de los distintos experimentos de este proyecto se siguió la siguiente metodología:

Para generar los pronósticos, los modelos serán utilizados de forma autorregresiva recursiva. Esto quiere decir que el modelo pronostica la demanda un paso a la vez, utilizando sus propias predicciones como predictores para generar los pronósticos siguientes. En la Fig. 14. se muestra gráficamente cómo funciona esta estrategia de pronóstico.




Fig. 14. Diagrama del proceso de predicción autorregresivo recursivo para predecir 3 steps a futuro utilizando los últimos 4 lags de la serie como predictores.

Para poder simular de la mejor forma posible durante la evaluación del desempeño de los modelos la forma en la que serán utilizados estos modelos, en lugar de las estrategias normales de validación cruzada, se utilizará una estrategia llamada backtesting, la cual permite tener en cuenta el comportamiento secuencial de los datos además de incluir características de la forma en la que se utilizará el modelo como la periodicidad en la que se generarán predicciones, la cantidad de pasos hacia delante que se generarán pronósticos y la importancia de ciertas fechas en la evaluación del modelo. En Fig. 15. Se muestra un ejemplo de una de las forma en las que se puede aplicar esta estrategia, donde el área verde representa a los datos utilizados para generar la predicción, el área gris representa a los datos que serán predichos pero que no se tendrán en cuenta para evaluar el modelo y el área azul representa a los datos que serán predichos y que se tendrán en cuenta para la evaluación del modelo. En cada iteración del backtesting, estas tres áreas se mueven siguiendo el itinerario de predicción definido.




Fig. 15. Diagrama del proceso de evaluación de un modelo usando backtesting.

Aplicando esta estrategia a nuestro caso de aplicación, el objetivo es que el modelo genere los viernes a las 12:00 el pronóstico de la demanda del periodo que empieza el lunes a las 00:00 horas y termina el domingo a las 23:00 horas de la semana siguiente, por lo cual tendrán que ser pronosticados 228 pasos hacia adelante (60 de los pasos que faltan para que acabe la semana en que se generan los pronósticos y 168 de la semana a pronosticar), además, ya que la demanda de la semana en la que se realizan los pronósticos se realizó la semana anterior, el pronóstico de las primeras 60 horas (los pronósticos de la mitad restante del viernes, el sábado y el domingo) no se tendrán en cuenta en la evaluación del modelo.

Adicionalmente, para ajustar los hiper parámetros de los modelos, el conjunto de datos será dividido en un conjunto de entrenamiento que contiene los datos del 1 de mayo de 2020 al 1 de julio de 2023, un conjunto de validación que va del 2 de julio del 2023 al 1 de marzo del 2024 a las 11:00 horas y un conjunto de prueba que va del 1 de marzo del 2024 a las 12:00 horas al 20 de mayo del 2024 a las 00:00 horas. Igualmente durante el ajuste de hiper parámetros se realiza backtesting pero en el conjunto de validación para evaluar a los modelos. La estrategia utilizada para el ajuste de los hiper parámetros fue la búsqueda bayesiana para reducir el tiempo que toma este proceso, y las métricas utilizadas para evaluar el desempeño de los distintos modelos fueron MAPE (Error Porcentual Absoluto Medio) y MAE (Error Absoluto Medio).

IV. LÍNEA BASE

A la hora de evaluar la calidad de una solución, es recomendable disponer de un modelo de referencia (Línea Base). Suele tratarse de una solución existente o un modelo muy sencillo que puede utilizarse como referencia para evaluar si merece la pena aplicar modelos más complejos. En esta ocasión, fueron definidos dos modelos como línea base:

A. Utilizar la demanda de la semana pasada como pronóstico

Dado que en el análisis exploratorio se observó una fuerte correlación entre la demanda de una hora y la demanda de hace una semana (168 horas) se definió como línea base una estrategia sencilla la cual consiste en usar el mismo valor de la demanda de la semana anterior como pronóstico.

Con esta solución se obtuvo un MAE de 394.123,92 y un MAPE de 0,042 al hacer backtesting con el conjunto de datos de prueba.

En Fig. 16. Se puede apreciar 3 gráficos (Un gráfico de valores residuales ordenados en el tiempo, Un gráfico de distribución de los residuos y Un gráfico que muestra la autocorrelación de los residuos) que permiten identificar

posibles patrones en los residuales, problemas en la distribución de los residuales y dependencias en los residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 16. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) para la línea base.

El patrón más reconocible en el gráfico de arriba es que el modelo tiene errores muy grandes en los festivos y las fechas una semana después de los festivos, esto debido a que el modelo no puede tener en cuenta este tipo de información a la hora de generar su pronóstico. Por otra parte los residuales tienen una distribución normal con media en cero, lo cual significa que no hay un sesgo significativo en el error. Por último, el gráfico de autocorrelación de los residuos muestra que existe una correlación significativa de una gran porción de los residuales, lo cual puede deberse a la gran cantidad de pasos hacia adelante que se predicen con el modelo.

B. Pronóstico del CND (Centro Nacional de Despacho)

La otra referencia que se utilizará para evaluar estos modelos son los pronósticos generados por el CND. Ya que la estrategia de evaluación es simular condiciones parecidas a las que usa el CND para generar sus predicciones, el desempeño de los modelos será comparado con el de sus pronósticos.

Esta referencia obtuvo un MAE de 303.008,15 y un MAPE de 0,032 al comparar su pronóstico con el conjunto de datos de prueba.

En Fig. 17. Se puede apreciar los 3 gráficos de residuales al comparar el pronóstico del CND con el conjunto de datos de prueba.

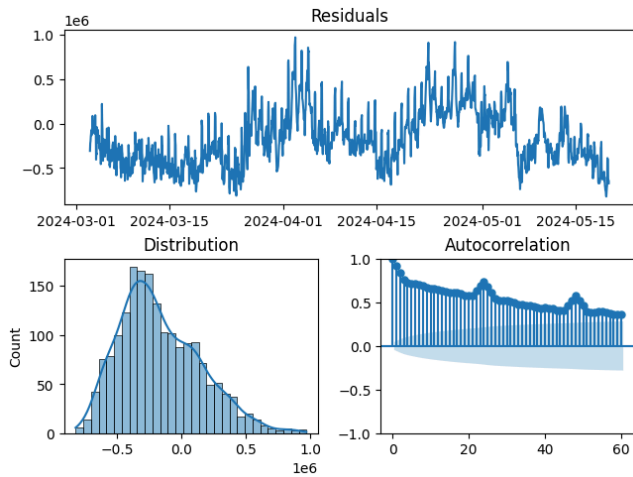


Fig. 17. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) para los pronósticos del CND.

En esta ocasión, los residuales están en un rango de valores más pequeño que los de la línea base, el patrón más reconocible en el gráfico de arriba es que el modelo tiene picos de error que se repiten la mayoría de los días, esto debido a que el modelo no puede tener en cuenta este tipo de información a la hora de generar su pronóstico. Por otra parte los residuales tienen una tendencia a ser negativos aunque sus picos de error tienden a ser más positivos. Por último, el gráfico de autocorrelación de los residuos muestra que existe un patrón de error que se repite diariamente.

V. MODELO DE REGRESIÓN LINEAL CON PENALIZACIÓN L2

En esta primera serie de experimentos se ajustó el parámetro alpha seguido de una etapa de selección de predictores a un modelo de regresión lineal con penalización L2. El valor de alpha obtenido luego del proceso de ajuste fue de 103, mientras que se redujo el número de lags para generar predicciones de 250 a 113 y el número de variables exógenas de 13 a 7.

Con esta solución se obtuvo un MAE de 293.945,6 y un MAPE de 0,0315 al hacer backtesting con el conjunto de datos de prueba. Estos valores son mucho mejores que los obtenidos con la estrategia de utilizar la demanda de la semana pasada como pronóstico y un poco mejores que los de los pronósticos del CND. El que el modelo haya obtenido mejores métricas que los pronósticos del CND no significa que sea mejor en general ya que están siendo comparados en una muestra menor a 3 meses, sin embargo sí que es muestra de que se pueden obtener buenos resultados en esta serie de tiempo usando modelos de este tipo.

En Fig. 18. Se puede apreciar los 3 gráficos de residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 18. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) para el modelo de regresión logística con penalización L2.

El mejor modelo de esta serie de experimentos parece verse afectado significativamente por los días festivos, además, al igual que con los pronósticos del CND, los residuales tienen tendencia a ser negativos y parece que tienen una distribución binomial. Por último, en el gráfico de autocorrelación de los residuos se puede observar que la autocorrelación baja de forma más pronunciada a medida que aumentan los pasos.

VI. MÁQUINA DE SOPORTE VECTORIAL

En esta segunda serie de experimentos se utilizó los descriptores seleccionados en los experimentos anteriores para ajustar los hiper parámetros de una máquina de soporte vectorial para regresión. Después del ajuste, los hiper parámetros con mejores resultados fueron:

- C: 0.27
- gamma: 0.0012
- kernel: RBF

Con estos hiper parámetros se obtuvo un MAE de 296.777,37 y un MAPE de 0.0317 al hacer backtesting con el conjunto de datos de prueba. Estos valores son un poco mejores que los de los pronósticos del CND pero peores que los obtenidos en la anterior serie de experimentos.

En Fig. 19. Se puede apreciar los 3 gráficos de residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 19. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) con la máquina de soporte vectorial.

El comportamiento de los residuos en este experimento es muy parecido al de la regresión lineal. La principal diferencia radica en que este modelo tiene picos de error mucho más pronunciados en semana santa (24 a 30 de marzo) y la semana siguiente (31 de marzo a 6 de abril).

VII. ÁRBOL DE DECISIÓN

En esta serie de experimentos se ajustó los hiper parámetros de un árbol de decisión de regresión. Después del ajuste, los hiper parámetros con mejores resultados fueron:

- max_depth: 16
- max_features: sqrt
- criterion: absolute_error
- min_samples_split: 32
- min_samples_leaf: 12

Con estos hiper parámetros se obtuvo un MAE de 400.260,26 y un MAPE de 0,043 al hacer backtesting con el conjunto de datos de prueba. Estos valores fueron peores que incluso los obtenidos con la estrategia de utilizar la demanda de la semana pasada como pronóstico.

En Fig. 20. Se puede apreciar los 3 gráficos de residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 20. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) con el árbol de decisión.

En estos gráficos se puede observar que el desempeño del modelo se ve muy afectado por los días festivos, principalmente en semana santa (24 a 30 de marzo) y la semana siguiente (31 de marzo a 6 de abril). Teniendo picos de error con una magnitud mayor a los 200.000 kilovatios hora.

VIII. GRADIENT BOOSTING (LIGHTGBM)

Uno de los modelos de machine learning con mejor desempeño en tareas de pronóstico de demanda son los modelos de regresión de la librería LightGBM, obteniendo mejores resultados que modelos de deep learning en distintas competiciones de kaggle. Por esto, en esta serie de experimentos se ajustó los hiper parámetros de un modelo de regresión de LightGBM. Después del ajuste, los hiper parámetros con mejores resultados fueron:

- n_estimators: 1300
- max_depth: 2
- learning_rate: 0.156
- reg_alpha: 0.4
- reg_lambda: 0.3

Con estos hiper parámetros se obtuvo un MAE de 281.421.93 y un MAPE de 0,03 al hacer backtesting con el conjunto de datos de prueba. Estos son los mejores resultados obtenidos hasta el momento.

En Fig. 21. Se puede apreciar los 3 gráficos de residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 21. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) con el regresor de LightGBM.

Revisando los gráficos de residuales, las principales ventajas de este modelo respecto al resto es la cantidad de residuos cercanos a cero en la mayoría de semanas, sin embargo, al igual que en el resto de modelos, el rendimiento de este modelo se ve afectado negativamente por los días festivos, principalmente en semana santa (24 a 30 de marzo) y la semana siguiente (31 de marzo a 6 de abril). Donde se presentan los picos de error de mayor magnitud.

IX. PERCEPTRÓN MULTICAPA

En esta última serie de experimentos se optó por ajustar los hiper parámetros de un perceptrón multicapa para esta tarea. Después del ajuste, los hiper parámetros con mejores resultados fueron:

- Arquitectura: 2 capas ocultas (64 y 32 neuronas) con función de activación ReLU
- optimizador: Adam
- learning_rate: 0.001
- paciencia del early stopping: 10

Con estos hiper parámetros se obtuvo un MAE de 330.273,9 y un MAPE de 0,036 al hacer backtesting con el conjunto de datos de prueba. Este experimento fué el único con métricas entre el pronóstico del CND y la línea base.

En Fig. 22. Se puede apreciar los 3 gráficos de residuales al pronosticar el conjunto de datos de prueba con este modelo.




Fig. 22. Gráfico de valores residuales ordenados en el tiempo (a), gráfico de distribución de los residuos (b) y gráfico de autocorrelación de los residuos (c) con el perceptrón multicapa.

Revisando los gráficos de residuales, las principales ventajas de este modelo respecto al resto es la cantidad de residuos cercanos a cero en la mayoría de semanas, sin embargo, al igual que en el resto de modelos, el rendimiento de este modelo se ve afectado negativamente por los días festivos, principalmente en semana santa (24 a 30 de marzo) y la semana siguiente (31 de marzo a 6 de abril). Donde se presentan los picos de error de mayor magnitud.

X. RESULTADOS

La Tabla I muestra una comparativa de las métricas de desempeño de las distintas soluciones presentadas en este artículo. Resaltado en negrita aparecen las métricas del modelo con mejor desempeño (LighGBM). Adicionalmente, como ya se comentó en este artículo, los modelos con mejores resultados en el conjunto de prueba no son necesariamente mejores en general que el modelo de la CND debido a la pequeña muestra con la que son comparados, sin embargo si es una señal de que estos modelos pueden tener un buen desempeño si son entrenados con un conjunto de datos más grande.

TABLA I
MÉTRICAS DE DESEMPEÑO DE LAS DISTINTAS SOLUCIONES EN EL CONJUNTO DE PRUEBA

Modelo	MAE	MAPE
Línea Base	394123,92	0,042
Pronóstico CND	303008,15	0,032
Regresión Lineal	293945,6	0,0315
Máquina de soporte vectorial	296777,37	0,0317
Árbol de decisión	400260,26	0,043
LighGBM	281421.93	0,03
Perceptrón multicapa	330273,9	0,036

Por otra parte, Fig. 23. muestra una gráfica con la demanda real del conjunto de prueba, las predicciones del modelo LightGBM y el pronóstico del CND. En esta

gráfica se puede apreciar mejor que el pronóstico del CND tiene una tendencia a pronosticar un consumo mucho menor a la demanda real en las primeras horas del día. Además, se puede apreciar que el modelo LigthGBM tiene un mejor desempeño en las semanas que se pueden considerar como “Normales” en las que no hay festivos y la semana anterior tampoco tiene festivos, mientras que los pronósticos del CND se ven menos afectados por este tipo de anomalías.




Fig. 23. Comparación de LigthGBM con pronóstico del CND en el conjunto de datos de prueba

XI. CONCLUSIONES

Al igual que en las principales problemáticas de inteligencia artificial (regresión, clasificación y agrupamiento), en tareas de pronóstico de series temporales son necesarias etapas de comprensión del problema, comprensión de los datos, preprocesamiento de los datos y evaluación del modelo. Sin embargo la forma en la que se realizan estas etapas son completamente diferentes ya que en todas es necesario tener en cuenta el comportamiento secuencial de estos datos. En este artículo se demostró la importancia de identificar patrones temporales en el comportamiento de los datos para la selección y generación de predictores que ayuden a mejorar el desempeño de los modelos implementados. Asimismo, se destacó la importancia de identificar las condiciones en las que será utilizado el modelo en producción para definir una estrategia de backtesting con el fin de evaluar correctamente

el desempeño del modelo en estas condiciones.

Los modelos con resultados más prometedores fueron LigthGBM, el modelo de regresión lineal con penalización L2 y la máquina de soporte vectorial. En trabajos futuros podría utilizarse una mayor cantidad de datos de entrenamiento y prueba para obtener mejores resultados y comparar su desempeño con los pronósticos del CND en una muestra más grande. Sin embargo, el aumentar el tamaño de este conjunto de datos implicará otras problemáticas que deberán ser abarcadas durante el diseño de la solución: por una parte, el impacto que tuvo la pandemia del Covid-19 en la demanda energética en marzo de 2020 introducirá una cantidad significativa de valores atípicos al conjunto de datos; por otra parte, la tendencia ascendente de la demanda energética a medida que avanzan los años. Este último factor puede afectar significativamente el desempeño de modelos basados en árboles de decisión debido a que no tienen la capacidad de extrapolar valores en un rango distinto a los vistos durante su entrenamiento. Esto puede ser una de las razones por las que el modelo de árbol de decisión tuvo un desempeño tan malo en el conjunto de prueba. Por esta razón, en una muestra más grande esta tendencia tendrá un mayor impacto en el desempeño final de los modelos.

REFERENCIAS

- [1] J. Amat Rodrigo and J. Escobar Ortiz, "skforecast (Version 0.12.0) [Computer software]," 2023. [Online]. Available: <https://doi.org/10.5281/zenodo.8382788>.
- [2] J. Jennifer, "Probabilistic forecasting of electricity demand in Colombia", Trabajo de grado - Maestría, Univ. Nac. Colomb., Medellín, 2024.
- [3] "Históricos de demanda". xm. Accedido el 28 de mayo de 2024. [En línea]. Disponible: <https://www.xm.com.co/consumo/historicos-de-demanda>
- [4] subsailor. "Time Series Forecasting: Is Simplicity the Key?" Kaggle. Accedido el 28 de mayo de 2024. [En línea]. Disponible: <https://www.kaggle.com/code/subsailor/time-series-forecasting-is-simplicity-the-key>